ขั้นตอนวิธีการลบแว่นตาออกจากภาพใบหน้าโดยอัตโนมัติ

The Algorithm for Automatic Eyeglasses Removal from Face Images

ธนภัทร จำเริญ [1] ดร.กิตติพล โหราพงศ์ [2]

สาขาคอมพิวเตอร์ คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเกษตรศาสตร์

50 ถนนงามวงศ์วาน แขวงลาดยาว เขตจตุจักร กรุงเทพมหานคร 10900

บทคัดย่อ

บทความนี้นำเสนอขั้นตอนวิธีการลบแว่นตาออกจากภาพใบหน้าโดยอัตโนมัติ เพื่อฟื้นฟูและปรับปรุงทัศนวิสัยบริเวณดวงตาที่ถูกบดบังจากกรอบแว่นตาและแสงสะท้อนบนเลนส์แว่นตา โดยมุ่งเน้นการสังเคราะห์ภาพใหม่ให้มีความสวยงามและสมจริง งานวิจัยนี้ประยุกต์ใช้โครงข่าย GAN โดยออกแบบข้อมูลนำเข้าแบบ 5 ช่องสัญญาณ (5-Channel Input) ประกอบด้วยภาพบริเวณใบหน้าแบบ RGB, หน้ากากแว่นตา (Mask) และจุดอ้างอิงรอบดวงตา (Eye Landmarks) นอกจากนี้ยังมีการใช้ Local Discriminator เพื่อเพิ่มความคมชัดบริเวณดวงตา ผลการทดลองพบว่าแบบจำลองสามารถสร้างภาพที่สวยงามและกลมกลืนกับผิวเดิม โดยให้ค่าประเมินความสมจริง (FID Score) ที่ 16.10 จากการทดสอบบนชุดข้อมูลสังเคราะห์ (FFHQ) จำนวน 300 ภาพ ในด้านประสิทธิภาพการจดจำใบหน้า ได้ทำการทดสอบบนชุดข้อมูลภาพถ่ายจริง (MeGlass) จำนวน 2,000 คู่ภาพ โดยกำหนดค่าอัตราการยอมรับผิด (FMR) ไว้คงที่ที่ร้อยละ 1 พบว่าเมื่อนำภาพทดสอบ (Probe) 2 กลุ่ม ได้แก่ ภาพหน้าสดต้นฉบับ และ ภาพที่ผ่านการลบแว่นตาด้วยแบบจำลอง ไปเปรียบเทียบกับภาพอ้างอิงหน้าสด (Gallery) จะมีอัตราการปฏิเสธผิด (FNMR) อยู่ที่ร้อยละ 7.02 และ 24.56 ตามลำดับ ผลลัพธ์นี้พิสูจน์ให้เห็นว่าแม้กระบวนการสังเคราะห์พิกเซลใหม่จะมีข้อจำกัดในการเปลี่ยนแปลงรายละเอียดเชิงลึกทางชีวมิติ แต่ขั้นตอนวิธีที่นำเสนอสามารถจัดการกับปัญหาการบดบังทางทัศนวิสัยและฟื้นฟูโครงสร้างใบหน้าได้อย่างยอดเยี่ยม

คำสำคัญ: การลบแว่นตา, โครงข่าย GAN, การเติมเต็มภาพ, คอมพิวเตอร์วิทัศน์, การจดจำใบหน้า

Abstract

This paper presents an automatic algorithm for eyeglasses removal from face images to restore and improve visibility in the eye region occluded by normal eyeglass frames and lens glare, focusing on synthesizing visually pleasing and realistic images. This research applies Generative Adversarial Networks (GANs) using a 5-channel input comprising RGB images, an eyeglasses mask, and eye landmarks. Furthermore, a local discriminator is utilized to enhance sharpness around the eyes. Experimental results demonstrate that the model generates aesthetically pleasing and seamless images, achieving a Fréchet Inception Distance (FID) score of 16.10 on 300 images from the FFHQ synthetic dataset. Regarding face recognition performance, testing was conducted on 2,000 image pairs from the MeGlass real-world dataset at a fixed False Match Rate (FMR) of 1%. The results revealed that when comparing the real glasses-free images and the model-synthesized glasses-removed images (Probes) against the reference glasses-free images (Gallery), the False Non-Match Rates (FNMR) were 7.02% and 24.56%, respectively. This demonstrates that although the pixel synthesis process inevitably modifies micro-biometric details, the proposed algorithm excellently manages visual occlusions and effectively restores the facial structure.

Keywords: Eyeglasses removal, Generative adversarial networks, Image inpainting, Computer vision, Face recognition

1. บทนำ

ในปัจจุบัน เทคโนโลยีคอมพิวเตอร์วิทัศน์ถูกนำมาประยุกต์ใช้ในงานตกแต่งและปรับปรุงคุณภาพภาพถ่าย (Image Retouching and Restoration) อย่างแพร่หลาย ปัญหาหนึ่งที่พบได้บ่อยในภาพถ่ายบุคคลคือการบดบังใบหน้า จากอุปกรณ์สวมใส่ โดยเฉพาะกรอบแว่นตาและแสงสะท้อนบนเลนส์แว่น ซึ่งบดบังดวงตาที่แท้จริงและส่งผลต่อความสวยงามของภาพ หรือเป็นอุปสรรคต่อการนำภาพไปใช้งานที่ต้องการเห็นโครงสร้างใบหน้าอย่างชัดเจน

แม้ว่าระบบจดจำใบหน้า (Face Recognition) ขั้นสูงในปัจจุบันจะสามารถทำงานร่วมกับภาพผู้สวมใส่แว่นตาใสได้ดี แต่ระบบมักจะทำงานผิดพลาดหรือประสิทธิภาพลดลงเมื่อเผชิญกับแสงสะท้อนบนเลนส์ หรือกรอบแว่นตาที่หนาจนบดบังลักษณะเฉพาะทางชีวมิติ เพื่อแก้ปัญหาดังกล่าว งานวิจัยนี้จึงนำเสนอขั้นตอนวิธีการลบแว่นตาออกจากภาพใบหน้าโดยอัตโนมัติ เพื่อใช้เป็นขั้นตอนการประมวลผลเบื้องต้น (Pre-processing) เป้าหมายหลักคือการปรับมาตรฐานข้อมูลภาพใบหน้า (Face Image Normalization) ให้อยู่ในรูปแบบหน้าสดที่ปราศจากสิ่งบดบัง โดยประยุกต์ใช้ Generative Adversarial Networks (GANs) [1] เพื่อสังเคราะห์ส่วนภาพบริเวณดวงตาขึ้นมาใหม่ให้มีความสวยงาม ไร้รอยต่อ และยังคงรักษาอัตลักษณ์ (Identity) ของบุคคลต้นฉบับไว้ได้อย่างสมบูรณ์

2. แนวคิด ทฤษฎี และงานวิจัยที่เกี่ยวข้อง

การเติมเต็มภาพ (Image Inpainting) เป็นเทคนิคทางคอมพิวเตอร์วิทัศน์ที่ใช้สร้างพิกเซลที่หายไปหรือถูกบดบังขึ้นมาใหม่ งานวิจัยนี้ประยุกต์ใช้เทคนิค Transfer Learning ร่วมกับสถาปัตยกรรม U-Net [2] ที่มีโครงข่าย ResNet34 [3] เป็นแกนหลักในการทำ Image Segmentation เพื่อระบุตำแหน่งของแว่นตา ในส่วนของการสังเคราะห์ภาพได้ประยุกต์ใช้โครงข่าย GANs ร่วมกับสถาปัตยกรรมตัวแยกแยะแบบ PatchGAN [4] เพื่อช่วยให้การตรวจสอบรายละเอียดพื้นผิวภาพมีความแม่นยำยิ่งขึ้น

เพื่อให้ภาพที่สร้างขึ้นมีความสวยงามและแนบเนียนในระดับการมองเห็นของมนุษย์ งานวิจัยนี้ใช้ฟังก์ชันความสูญเสียเชิงการรับรู้ (Perceptual Loss) [5] ผ่านโครงข่าย VGG19 ซึ่งใช้ในการคำนวณ Content Loss เพื่อรักษาโครงสร้างใบหน้า และ Style Loss เพื่อปรับสมดุลพื้นผิวภาพ ในส่วนของการประเมินผล มีการใช้มาตรวัด Fréchet Inception Distance (FID) [6] สำหรับประเมินความสมจริงทางทัศนวิสัย และประเมินการรักษาอัตลักษณ์บุคคลด้วยแบบจำลอง ArcFace [7]

3. วิธีดำเนินการวิจัย

3.1 ภาพรวมของระบบ (System Overview)

ขั้นตอนวิธีการลบแว่นตาที่นำเสนอ เป็นสถาปัตยกรรมแบบครบวงจร (End-to-end) โดยมีลำดับขั้นตอนการทำงานแสดงดังรูปที่ 1

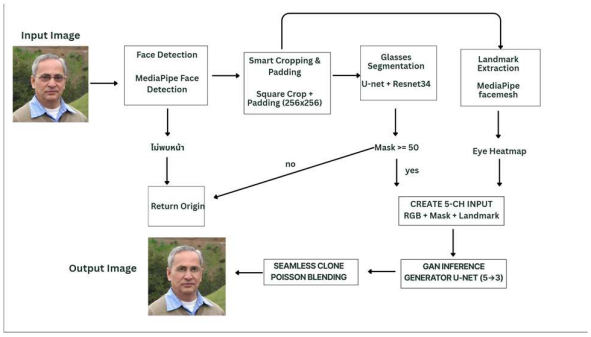

รูปที่ 1 ภาพรวมขั้นตอนวิธีการลบแว่นตาออกจากภาพใบหน้าแบบอัตโนมัติ

กระบวนการเริ่มต้นจากการนำภาพเข้าสู่แบบจำลองตรวจจับใบหน้าด้วย MediaPipe หากไม่พบใบหน้า ระบบจะคืนค่าภาพต้นฉบับกลับไป ในกรณีที่พบใบหน้า ระบบจะทำการคำนวณตัดภาพและขยายพื้นที่กรอบหน้าต่างออกร้อยละ 50 (Smart Cropping & Padding) เป็นขนาด 256x256 พิกเซล จากนั้นส่งเข้าสู่แบบจำลองแบ่งส่วนภาพ หากพื้นที่หน้ากากแว่นตามีขนาดน้อยกว่า 50 พิกเซล ระบบจะถือว่าไม่มีแว่นตาและคืนภาพเดิม แต่หากพบหน้ากากแว่นตา ระบบจะสกัดจุดสังเกตและสร้างข้อมูล 5 ช่องสัญญาณ เพื่อส่งให้ตัว

สร้าง (Generator) สังเคราะห์ดวงตาใหม่ ท้ายที่สุดภาพจะถูกนำไปผสานกลับด้วยเทคนิค Seamless Clone

3.2 สถาปัตยกรรมการแบ่งส่วนภาพแว่นตา (Eyeglasses Segmentation Architecture)

กระบวนการแรกของระบบคือการค้นหาและระบุตำแหน่งของแว่นตา งานวิจัยนี้ใช้สถาปัตยกรรม U-Net [2] ร่วมกับตัวเข้ารหัส (Encoder) แบบ ResNet34 [3] ที่ผ่านการฝึกสอนล่วงหน้าบนชุดข้อมูล ImageNet ซึ่งใช้บล็อกเรซิดวล (Residual Block) ที่มีการเชื่อมต่อแบบทางลัด (Skip connection) เพื่อรวมข้อมูลอินพุต x เข้ากับฟังก์ชันการแปลง F(x) ดังสมการที่ (1)

$$y = F(x, \{W_i\}) + x \quad (1)$$

แบบจำลองรับข้อมูลนำเข้าเป็นภาพใบหน้าสี $\mathrm{I_{orig}} \in \mathrm{R}^{3\times256\times256}$ผ่านกระบวนการสกัดลักษณะเด่นเพื่อทำนายผลลัพธ์ในรูปแบบของหน้ากากความน่าจะเป็น จากนั้นใช้การกำหนดค่าขีดแบ่ง (Thresholding) เพื่อแปลงให้เป็นหน้ากากไบนารี $\mathrm{M} \in \mathrm{R}^{1\times256\times256}$และนำไปผ่านกระบวนการทางสัณฐานวิทยา (Morphological Dilation) ด้วยเคอร์เนลขนาด 10x10 พิกเซล เพื่อขยายขอบเขตของหน้ากากให้ครอบคลุมกรอบแว่นตาอย่างสมบูรณ์ ตัวอย่างผลลัพธ์ภาพหน้ากากแว่นตาที่ได้จากกระบวนการนี้แสดงดังรูปที่ 2

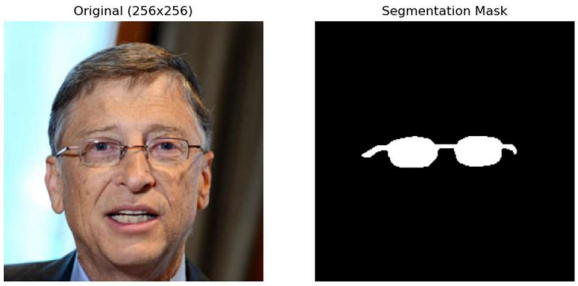

รูปที่ 2 ตัวอย่างภาพใบหน้าต้นฉบับและหน้ากากไบนารี (Binary Mask) ที่ได้จากแบบจำลองการแบ่งส่วนภาพก่อนนำไปขยายขอบเขต

3.3 การเตรียมข้อมูลนำเข้าแบบ 5 ช่องสัญญาณ (5-Channel Input Formulation)

เพื่อชี้นำให้ตัวสร้าง (Generator) สามารถสังเคราะห์ดวงตาได้อย่างถูกต้อง งานวิจัยนี้ได้ออกแบบการต่อข้อมูล (Concatenation) แบบ 5 ช่องสัญญาณตามสมการคณิตศาสตร์ดังนี้:

1. **ภาพที่ถูกปิดบังบริเวณแว่นตา (Masked Image):** นำภาพต้นฉบับมาลบข้อมูลบริเวณแว่นตาทิ้ง กำหนดให้เป็น $\mathrm{I_{masked}} \in \mathrm{R}^{3\times256\times256}$ดังสมการที่ (2)

$$\mathrm{I_{masked}} = \mathrm{I_{orig}} \odot (1 - \mathrm{M}) \quad (2)$$

2. **หน้ากากแว่นตา (Mask):** ข้อมูล $\mathrm{M} \in \mathrm{R}^{1\times256\times256}$ ทำหน้าที่บอกบริเวณที่ต้องทำการสังเคราะห์พิกเซลใหม่
3. **แผนภาพจุดอ้างอิงรอบดวงตา (Eye Landmark Heatmap):** ประยุกต์ใช้ MediaPipe FaceMesh [8] ในการสกัดพิกัดขอบตาและวาดเส้นขอบตาทั้งสองข้าง รวม 32 จุด และวาดเส้นขอบตาลงบนภาพพื้นดำ กำหนดเป็น $\mathrm{L} \in \mathrm{R}^{1\times256\times256}$ทำหน้าที่เป็นโครงร่างนำทาง (Structural Prior) ป้องกันปัญหาดวงตาผิดสัดส่วนหรือบิดเบี้ยว

นำข้อมูลทั้ง 3 ส่วนมาต่อกันตามแกนช่องสัญญาณ จะได้เทนเซอร์ข้อมูลนำเข้า $\mathrm{X_{in}}$ สำหรับโครงข่าย GAN ดังสมการที่ (3)

$$X_{in} = [I_{masked}, M, L] \in R^{5\times256\times256} \quad (3)$$

3.4 สถาปัตยกรรมโครงข่าย GAN (GAN Architecture)

โครงข่ายประกอบด้วยตัวสร้าง (G) และตัวแยกแยะ (D) ที่ทำงานแบบเป็นปฏิปักษ์ต่อกัน

1. ตัวสร้าง (Generator): ใช้สถาปัตยกรรมแบบ U-Net ที่มีการเชื่อมต่อข้าม (Skip Connections) แบบจำลองรับข้อมูลนำเข้า X_{in} (5 ช่องสัญญาณ) ผ่านชั้นเข้ารหัสและถอดรหัสอย่างละ 8 ระดับ (Encoder/Decoder) โดยผลลัพธ์สุดท้ายจะผ่านฟังก์ชันกระตุ้น Tanh เพื่อจำกัดค่าสีให้อยู่ในช่วง [-1, 1] ก่อนแปลงกลับเป็นภาพสี $I_{gen} \in R^{3\times256\times256}$

2. ตัวแยกแยะ (Discriminators): เพื่อแก้ปัญหาภาพเบลอเฉพาะจุด งานวิจัยนี้ใช้สถาปัตยกรรม PatchGAN [4] จำนวน 2 โครงข่ายควบคู่กัน:

- Global Discriminator (D_{global}): รับข้อมูลภาพทั้งใบหน้าขนาด $3 \times 256 \times 256$ พิกเซล เพื่อประเมินความสมจริงโดยรวม
- Local Discriminator ($\mathrm{D_{local}}$): รับข้อมูลเฉพาะบริเวณดวงตาที่ถูกตัดแบ่งให้มีขนาด $3 \times 128 \times 128$ พิกเซล โดยอ้างอิงจุดกึ่งกลางจากหน้ากาก M เพื่อบังคับให้ตัวสร้างสังเคราะห์รายละเอียดเชิงลึก เช่น ชั้นตาและขนตา ให้คมชัด

3.5 ฟังก์ชันความสูญเสียและกระบวนการหลังการประมวลผล (Loss Functions & Post-processing)

เพื่อควบคุมทิศทางการเรียนรู้ ฟังก์ชันความสูญเสียรวม (L_{total}) จึงถูกกำหนดรูปแบบให้สอดคล้องกับการใช้งานตัวแยกแยะแบบคู่ขนาน ดังสมการที่ (4)

$$L_{total} = L_{adv_global} + (\lambda_{loc} L_{adv_local}) + (\lambda_{L1} L_{L1}) + (\lambda_{con} L_{con}) + (\lambda_{sty} L_{sty}) \quad (4)$$

โดย L_{adv} คือฟังก์ชันความสูญเสียแบบ Adversarial ของ LSGAN (สมการกำลังสองน้อยที่สุด) เพื่อแก้ไขปัญหา Gradient Vanishing L_{L1} คือความสูญเสียระดับพิกเซล L_{con} และ L_{sty} คือความสูญเสียเชิงการรับรู้ (Perceptual Loss) [5] ผ่านโครงข่าย VGG19

งานวิจัยนี้ได้กำหนดค่าน้ำหนักเพื่อเน้นความสมจริงของพื้นผิวภาพ โดยกำหนด $\lambda_{L_1} = 10.0$, $\lambda_{con} = 10.0$ และเพิ่มค่าน้ำหนักของ Style Loss λ_{sty} ให้สูงถึง 250 ในช่วงแรกของการฝึกสอน เพื่อกระตุ้นให้ตัวสร้างมุ่งเน้นการปรับสมดุลพื้นผิวภาพ (Texture) บริเวณรอยต่อของหน้ากากให้กลมกลืนกับผิวหนังรอบข้าง

หลังจากการสังเคราะห์ภาพเสร็จสิ้น ระบบจะทำการผสานเฉพาะพื้นที่ที่ถูกวาดใหม่ใน I_{gen} กลับลงไปบนภาพต้นฉบับ I_{orig} ด้วยเทคนิคการผสานแบบปัวซอง (Poisson Blending / Seamless Clone) ผ่านไลบรารี OpenCV ซึ่งช่วยลดปัญหาความไม่สม่ำเสมอของแสงสว่าง ส่งผลให้ภาพผลลัพธ์สุดท้ายมีความสมบูรณ์

3.6 รายละเอียดการฝึกสอนแบบจำลอง (Implementation Details)

งานวิจัยนี้ดำเนินการพัฒนาและฝึกสอนแบบจำลองผ่านเฟรมเวิร์กการเรียนรู้เชิงลึก PyTorch โดยมีรายละเอียดดังต่อไปนี้

1. การจัดการชุดข้อมูลและการแบ่งข้อมูล:

สำหรับการฝึกสอนแบบจำลอง งานวิจัยนี้ใช้ชุดข้อมูลภาพใบหน้าความละเอียดสูง CelebAMask-HQ [10] จำนวน 30,000 ภาพ ผู้วิจัยได้ทำการแบ่งชุดข้อมูล (Data Splitting) ออกเป็นชุดข้อมูลสำหรับฝึกสอน (Training Set) ร้อยละ 90 (27,000 ภาพ) และชุดข้อมูลสำหรับตรวจสอบ (Validation Set) ร้อยละ 10 (3,000 ภาพ) ข้อมูลนำเข้ามีการขยายชุดข้อมูล (Data Augmentation) แบบสุ่ม เช่น การพลิกภาพแนวนอน และการหมุนภาพ (Random Rotation) ในช่วงองศา -20 ถึง 20 องศา

2. การฝึกสอนแบบจำลองแบ่งส่วนภาพ (Segmentation Model):

แบบจำลองถูกฝึกสอนเป็นจำนวน 20 รอบ (Epochs) โดยกำหนดขนาดของชุดข้อมูลย่อย (Batch Size) เท่ากับ 16 ภาพต่อรอบ ใช้ Adam Optimizer โดยตั้งค่าอัตราการเรียนรู้ (Learning Rate) ที่ 1×10^{-4} ใช้ฟังก์ชันความสูญเสียแบบ BCEWithLogitsLoss ระบบทำการประเมินค่าความสูญเสียจาก Validation Set ในทุกรอบและบันทึกค่าน้ำหนักของแบบจำลองที่ดีที่สุด (Best Weights Checkpoint)

3. การฝึกสอนโครงข่าย GAN:

เนื่องจากข้อมูลนำเข้ามีขนาด 5 ช่องสัญญาณ และใช้ตัวแยกแยะ 2 ชุด ขนาด Batch Size จึงถูกกำหนดไว้ที่ 4 ภาพต่อรอบ ใช้ Adam Optimizer ในการปรับค่าน้ำหนักทั้งตัวสร้างและตัวแยกแยะ โดยตั้งค่าอัตราการเรียนรู้ที่ 2×10^{-4} และปรับค่า $\beta_1 = 0.5, \beta_2 = 0.999$ การฝึกสอนระยะแรก (Phase 1) ดำเนินการเป็นจำนวน 50 รอบ (Epochs) โดยใช้การลดระดับอัตราการเรียนรู้ (Learning Rate Scheduler) ตามจำนวนรอบที่กำหนด ในระหว่างกระบวนการฝึกสอนโครงข่าย GAN แบบจำลองจะเรียนรู้การสังเคราะห์ภาพดวงตาขึ้นใหม่ โดยตัวอย่างความก้าวหน้าของการเรียนรู้และลักษณะข้อมูลที่ใช้ฝึกสอนแสดงดังรูปที่ 3

รูปที่ 3 ตัวอย่างข้อมูลภาพที่ใช้ในกระบวนการฝึกสอนโครงข่าย GAN (แถวบน: ภาพนำเข้าที่ถูกปิดบังดวงตา, แถวกลาง: ภาพที่แบบจำลองสังเคราะห์ขึ้นในระหว่างการฝึกสอน, และ แถวล่าง: ภาพความจริงพื้นฐาน)

4. ผลการวิจัย

การประเมินผลประสิทธิภาพของแบบจำลองแบ่งออกเป็น 2 ส่วนหลัก ได้แก่ การประเมินด้านความสมจริงของภาพ (Visual Quality) ซึ่งดำเนินการทดสอบบนชุดข้อมูลสังเคราะห์ FFHQ จำนวน 300 ภาพ และการประเมินด้านการรักษาอัตลักษณ์บุคคล (Biometric Preservation) ซึ่งดำเนินการทดสอบบนชุดข้อมูลภาพถ่ายจริง MeGlass [9] จาก 114 บุคคล โดยสุ่มสร้างเป็น 2,000 คู่ภาพ (ประกอบด้วยคู่ภาพบุคคลเดียวกันและคู่ภาพต่างบุคคล)

4.1 การประเมินด้านคุณภาพและความสมจริง (Visual Quality)

แบบจำลองให้ค่าประเมินความสมจริง (FID Score) [6] ของชุดข้อมูลสังเคราะห์ FFHQ ที่ระดับ 16.10 แสดงให้เห็นว่าภาพที่ผ่านการลบแว่นตามีคุณภาพสูง พื้นผิวและแสงเงากลมกลืนกับภาพใบหน้าจริงอย่างเป็นธรรมชาติ เพื่อให้เห็นถึงประสิทธิภาพของโครงข่าย GAN รูปที่ 4 แสดงให้เห็นถึงผลลัพธ์เปรียบเทียบระหว่างภาพชุดข้อมูลสังเคราะห์ที่สวมแว่นตา (Input) และภาพผลลัพธ์ที่ผ่านขั้นตอนวิธีการลบแว่นตา (Output)

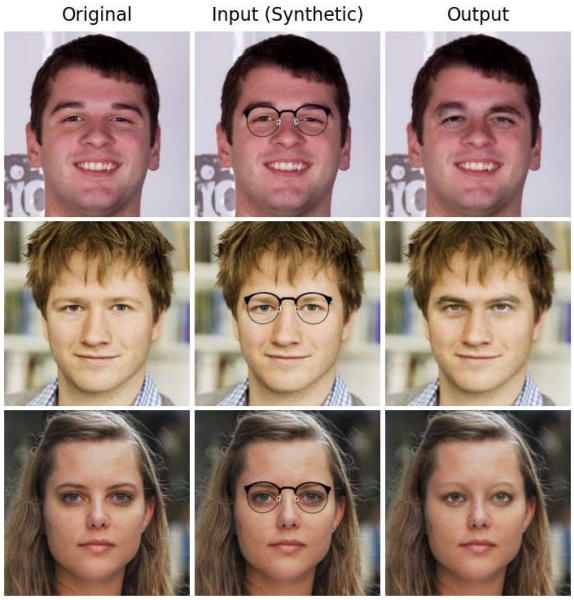

รูปที่ 4 ตัวอย่างผลลัพธ์การลบแว่นตาบนชุดข้อมูลภาพสังเคราะห์ FFHQ

นอกจากนี้ เพื่อประเมินความทนทานต่อสภาวะแวดล้อมที่หลากหลาย (Robustness) ของแบบจำลองต่อข้อมูลในสภาพแวดล้อมจริง ผู้วิจัยได้นำแบบจำลองไปทดสอบกับชุดข้อมูลภาพถ่ายจริง MeGlass ซึ่งประกอบด้วยกรอบแว่นตาที่มีความหลากหลายและสภาพแสงสะท้อนที่ซับซ้อนกว่าภาพสังเคราะห์ ดังแสดงผลลัพธ์ในรูปที่ 5 จะเห็นได้ว่าแบบจำลองยังคงรักษาประสิทธิภาพในการลบกรอบแว่นตาและสามารถเติมเต็มพิกเซลผิวหนังและดวงตาได้อย่างแนบเนียน

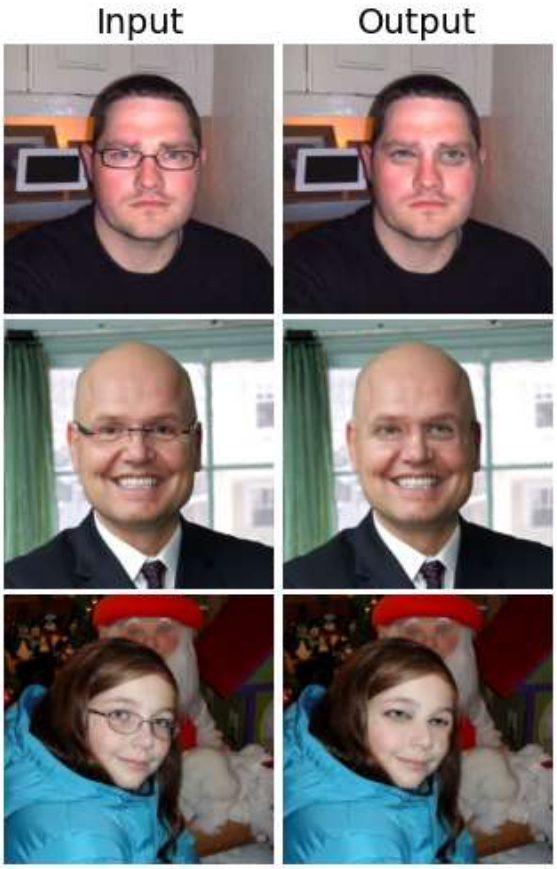

รูปที่ 5 ตัวอย่างผลลัพธ์เชิงประจักษ์ (Qualitative Results) การลบแว่นตาบนชุดข้อมูลภาพถ่ายจริง MeGlass เปรียบเทียบระหว่างภาพต้นฉบับสวมแว่นตา (ซ้าย) และภาพผลลัพธ์จากแบบจำลอง (ขวา)

4.2 การประเมินด้านชีวมิติ (Biometric Preservation)

งานวิจัยนี้ประเมินการรักษาอัตลักษณ์บุคคลด้วยแบบจำลอง ArcFace [7] โดยมุ่งเน้นการทดสอบบนชุดข้อมูลภาพถ่ายจริง MeGlass [9] เพื่อสะท้อนประสิทธิภาพของแบบจำลองในสภาพแวดล้อมการใช้งานจริง โดยอ้างอิงมาตรฐานการประเมินระบบชีวมิติผ่านการกำหนดอัตราการยอมรับผิด (False Match Rate: FMR) ไว้คงที่ที่ร้อยละ 1.0

ในการทดสอบ ได้กำหนดให้ "ภาพอ้างอิงหน้าสด (Gallery)" เป็นภาพหลักในฐานข้อมูล จากนั้นจึงนำภาพทดสอบ (Probe) จำนวน 2 กลุ่ม ได้แก่ 1) ภาพหน้าสดต้นฉบับ (Real Glasses-free) และ 2) ภาพที่ผ่านการลบแว่นตาด้วยแบบจำลอง (Synthesized) มาประมวลผลค่าเมตริกระยะห่าง (Distance metric) ร่วมกับภาพอ้างอิงดังกล่าว เพื่อวัดค่าอัตราการปฏิเสธผิด (False Non-Match Rate: FNMR) ได้ผลลัพธ์ดังตารางที่ 1

ตารางที่ 1 ผลการประเมินอัตราการปฏิเสธผิด (FNMR) เมื่อเปรียบเทียบกับภาพอ้างอิงหน้าสด (Gallery) ที่ระดับ FMR ร้อยละ 1

รูปแบบภาพทดสอบ (Probe Images)	**FNMR @ FMR = 1.0%**
ภาพหน้าสดต้นฉบับ (Real Glasses-free)	7.02%
ภาพที่ผ่านการลบแว่นตาด้วยแบบจำลอง (Synthesized)	24.56%

จากตารางที่ 1 พบว่าเมื่อนำภาพหน้าสดต้นฉบับ (Real Glasses-free) มาเป็นภาพทดสอบ จะมีค่า FNMR ที่เป็นเส้นฐาน (Baseline) อยู่ที่ร้อยละ 7.02 ในขณะที่ภาพผลลัพธ์ที่ผ่านการลบแว่นตาด้วยแบบจำลอง (Synthesized) มีค่า FNMR เพิ่มขึ้นเป็นร้อยละ 24.56 ปรากฏการณ์ที่ค่า FNMR สูงขึ้นนี้ เป็นข้อจำกัด (Trade-off) ที่พบได้ทั่วไปในกระบวนการโครงข่าย GAN ที่ทำการสังเคราะห์พิกเซลใหม่ (Hallucination) เพื่อทดแทนส่วนที่ถูกบดบังจากแว่นตา ส่งผลให้รายละเอียดเชิงลึกทางชีวมิติบางประการ (Micro-biometric features) เช่น ถุงใต้ตา หรือรอยพับชั้นตา คลาดเคลื่อนไปจากภาพความจริงพื้นฐาน อย่างไรก็ตาม เมื่อพิจารณาจากประสิทธิภาพโดยรวม ผลลัพธ์นี้ยืนยันว่าแบบจำลองสามารถทำหน้าที่ปรับภาพให้อยู่ในมาตรฐานเดียวกัน (Normalized Faces) และกู้คืนทัศนวิสัยของใบหน้าได้อย่างดีเยี่ยมในเชิงคุณภาพทางทัศนวิสัย

5. สรุปผลการวิจัย

ขั้นตอนวิธีการลบแว่นตาแบบอัตโนมัติด้วยแบบจำลอง GAN 5 ช่องสัญญาณ มีประสิทธิภาพสูงในการฟื้นฟูภาพที่ถูกบดบังด้วยกรอบแว่นตาปกติและแสงสะท้อน สร้างผลลัพธ์ที่มีความสวยงาม สมจริง และไร้รอยต่อ ในด้านการประยุกต์ใช้กับระบบจดจำใบหน้า แม้การเติมเต็มภาพจะก่อให้เกิดค่า FNMR ที่ร้อยละ 24.56 บนชุดข้อมูลทดสอบ 2,000 คู่ภาพ ซึ่งสะท้อนถึงการเปลี่ยนแปลงรายละเอียดระดับพิกเซล แต่ระบบสามารถแก้ปัญหาการบดบังทางกายภาพและฟื้นฟูโครงสร้างใบหน้าโดยรวมได้อย่างสมบูรณ์ วิธีการที่นำเสนอนี้จึงมีความเหมาะสมสำหรับการนำไปประยุกต์ใช้ในงานตกแต่งภาพถ่ายบุคคล การปรับปรุงภาพเพื่อทัศนวิสัยที่ดีขึ้น และสามารถบูรณาการเป็นแบบจำลองประมวลผลเพื่อปรับมาตรฐานภาพเบื้องต้น (Pre-processing Module) ให้กับฐานข้อมูลได้

เอกสารอ้างอิง

[1] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, “Generative adversarial nets,” Advances in Neural Information Processing Systems, vol. 27, 2014.

[2] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI 2015), pp. 234-241, Springer, 2015.

[3] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 770-778, 2016.

[4] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros, “Image-to-image translation with conditional adversarial networks,” Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 1125-1134, 2017.

[5] J. Johnson, A. Alahi, and L. Fei-Fei, “Perceptual losses for real-time style transfer and super-resolution,” European Conference on Computer Vision, pp. 694-711, Springer, 2016.

[6] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler, and S. Hochreiter, “GANs trained by a two time-scale update rule converge to a local Nash equilibrium,”

Advances in Neural Information Processing Systems, vol. 30, 2017.
[7] J. Deng, J. Guo, N. Xue, and S. Zafeiriou, “ArcFace: Additive Angular Margin Loss for Deep Face Recognition,” Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 4690-4699, 2019.
[8] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, M. Hays, F. Zhang, C.-L. Chang, M. G. Yong, J. Lee, et al., “MediaPipe: A framework for building perception pipelines,” arXiv preprint arXiv:1906.08172, 2019.
[9] J. Guo, X. Zhu, Z. Lei, and S. Z. Li, “Face synthesis for eyeglass-robust face recognition,” Proc. 13th Chinese Conference on Biometric Recognition (CCBR 2018), Lecture Notes in Computer Science, vol. 10996, pp. 275-284, Springer, Cham, 2018.
[10] C.-H. Lee, Z. Liu, L. Wu, and P. Luo, "MaskGAN: Towards Diverse and Interactive Facial Image Manipulation," Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5549-5558, 2020.